赵勇臻 AI Agent 基础设施 / 后端开发

zhaoyzzz@outlook.com · yongzhen.space
(+86) 181-6810-0075 · 2002.3.22 · 甘肃庆阳



教育背景

南京大学

硕士 · 软件工程专业 2024.09 - 2026.06

本科 · 软件工程专业 2020.09 - 2024.06

技术经历

字节跳动 · 组件 · 后端开发 / AI Agent 2025.12 - 2026.05 实习；2026.07 - 至今 正式

中间件 AI 提效

- 项目简介： 面向中间件研发与运维的 AI 提效平台，负责知识库、Oncall Agent、排障 Skill、评测与研发流程。
- **Oncall 与知识库**： 建设覆盖 **26 个中间件**组件的三级知识库（AI 知识库 / 代码仓库 / Wiki 长尾召回）；在 Fops 建统一 Oncall 入口，配置 26 个问题分类与值班计划。
- **工具与 Skill**： 封装 5 个排障查询 Skill 和 21 个组件接入/开发 Skill，基于内部 Agent 平台搭建 Oncall Agent 与机器人入口。
- **评测与流程**： 建设 **104 题**问答测评与真实排障样例，准确率从**约 50% 提升至 80%+**；推进 Flux + Meego 流程在 **3** 个需求中落地，季度拦截率约 **30%**，节省 **4 人日+**。

日志组件与成本治理

- 项目简介： 负责日志组件与成本治理，覆盖日志采集转发、AI 日志分析与成本优化。
- 系统设计： 兼容新旧写入器与异步发送，通过配置中心将日志路由到短 TTL 存储，业务免改代码与发版。
- **AI 日志分析**： 识别重复输出、RPC、Debug、配置、ABTest、不可读字段等噪声，生成裁剪/降级/转存建议；用 JSON Schema 约束输出，代码侧校验过滤错误规则。
- **控制面与量化**：将分析、规则确认、发布与收益观察收敛到统一控制面，跟踪规则数、状态与成本趋势；单季度日均日志成本下降约 三分之一，其中纯治理约 四成，配置投入从 3 人日降至 0.1 人日，合计约 **50 人日**效率收益。

流量治理组件

- 项目简介： 面向业务流量的统一治理组件，可接入 RPC、数据库、消息队列等；负责 BMQ 适配与前端控制面。
- **BMQ 适配**： 抽象多种消息客户端差异，将统一识别、观测、限流与降级接入生产/消费入口；覆盖同步、批量、异步与单条、批量消费。
- 验证： 申请 BMQ/MQ 测试资源，建设测试 Skill 固化各框架测试步骤与验收方式；针对 7 种消费处理模型 × 4 个消息框架完成 **28** 次集成测试，四客户端适配已完成（进度 **90%**）。
- **控制面**： 负责前端控制面开发，支持规则配置与运行效果查看。

金融网络专线

- 项目简介：高流量基础组件，负责金融渠道专线的日常维护与功能演进，覆盖线路状态、连接与配置等日常问题，保障金融渠道稳定接入。

腾讯 · CSIG · TRTC · 音视频 SDK 2025.06 - 2025.09 实习

- **漏回声检测：** 自动监控 AEC 效果、替代人工反馈的算法；负责算法选型与评测。对比 AECMOS / GCC-PHAT / WebRTC 后选择 **WebRTC**；通过 EMA 20s→3s、缓存 render 音频与分窗匹配，将精准率从约 **60%** 提升至近 **100%**，召回率约 **50%**；检查 **123** 条语料并拼接 **400** 个用例，搭建自动化评测。
- **音色评估：** Android 双声道 KTV 选声道；**149** 组盲测提出「**频谱高频能量和**」，分类 **95%**、差体验低于 **0.2%**。

网易 · 伏羲 · 后端系统开发 2023.06 - 2023.09 实习

- **项目简介：** DDL 是 AOP 框架的跨语言序列化组件，负责 DDL / JSON / bytes / Python 对象双向转换，覆盖 Rust / Java / Python 三端；我负责功能、类型安全、测试和性能。
- **功能与质量：** 扩展积类型、和类型、递归类型与 NumPy，提供 enc_hook/dec_hook 扩展点；引入 type hints 与 mypy；基于 PBT 完善随机测试，将覆盖率提升至 **90%** 并接入 CI。
- **性能优化：** 通过类型特化（按类型生成 constructor，消除 switch 开销）、C API 扩展与 msgspec 复用、NumPy 零拷贝、缓存与关闭冗余校验，将序列化平均耗时从约为 protobuf 的 **50** 倍降至 **2** 倍以内，部分场景低于 **1/4**。

其他项目 · 编译器 / 操作系统 / LLM

Transformer-LLM 2025.03 - 2025.04

- **项目内容：** 从零实现基于 **Transformer** 架构的语言模型，完成训练、微调、对齐与部署链路。
- **性能优化：** 通过 Profiling 定位计算与显存瓶颈，实践混合精度、Triton 融合算子、Tiling/Online Softmax 与 PagedAttention 等优化。

SysY-RISCV 编译器 2024.07 - 2024.09

- **项目内容：** 使用 **C++17** 实现 SysY 到 RISC-V 的编译器，生成代码的性能达到 **GCC O2 水准**。
- **编译优化：** 基于 **SSA IR** 实现死代码消除、常量折叠、循环优化与寄存器分配等优化 Pass。
- **团队协作：** 担任组长并负责后端架构、指令选择与代码生成，推进团队协作和性能调优。

miniOS 操作系统 2022.03 - 2022.06

- **项目内容：** 使用 **C** 实现支持多处理器的教学操作系统，完成内存管理与内核多线程等核心模块。
- **核心实现：** 分别实现基于链表、红黑树与 **slab** 的内存分配器，对比其时间、空间与碎片化权衡，并设计 Fast Path / Slow Path。

专业技能

- **AI / Agent：** 熟悉 LLM、Transformer 与 PyTorch，具备 Tool Calling、RAG、Context Engineering、Agent Evaluation 等 AI Agent 开发经验。
- **后端与分布式系统：** Go、Python、C/C++；熟悉 Linux、并发编程、数据库、Kafka、etcd、Docker / Kubernetes 及云原生基础设施。
- **系统与性能：** 具备操作系统、编译器、程序语言与运行时基础，熟悉 Benchmark、Profiling、火焰图分析及端到端性能优化。
- **工程质量：** 具备复杂系统调试与问题定位经验，熟悉自动化测试、Property-Based Testing、静态类型检查与可观测性建设。